



PROJETO PRÁTICO

Analisando conjuntos de dados e suas fontes de dificuldade

Descrição. Os dados constituem insumos fundamentais para as técnicas de Aprendizado de Máquina. Em problemas supervisionados, diversos fatores podem comprometer a qualidade dos dados e, conseqüentemente, o desempenho dos modelos, como ruídos nos atributos preditivos e nos rótulos, valores ausentes, desbalanceamento severo entre as classes, entre outros. Neste projeto, vocês irão trabalhar em trios e selecionar um conjunto de dados do repositório TabZilla para analisar e aplicar um pipeline completo de Aprendizado de Máquina. O TabZilla reúne conjuntos de dados reconhecidamente desafiadores na literatura. O objetivo principal será investigar por que o conjunto escolhido é difícil para técnicas de Aprendizado de Máquina, identificando características dos dados que possam contribuir para essa dificuldade e analisando em quais regiões, subconjuntos ou tipos de instâncias os modelos tendem a apresentar maior taxa de erro. A ideia é ir além da comparação global de desempenho entre algoritmos e compreender, de forma mais detalhada, quando, onde e por que os modelos falham.

1 Escolhendo os dados

A área de Aprendizado de Máquina (AM) dispõe de diversos repositórios e *benchmarks* de dados públicos. Entre eles, o *benchmark* TabZilla reúne 36 conjuntos de dados identificados como desafiadores em um estudo da literatura (McElfresh et al., 2023).

No projeto, a turma será dividida em trios e cada um escolherá um dos conjuntos de dados da Tabela 1, pertencentes ao TabZilla, para trabalhar (os conjuntos podem ser baixados em https://www.openml.org/search?type=study&study_type=task&id=379&sort=tasks_included).

Escolha qual conjunto de dados seu grupo pretende usar em: <https://docs.google.com/spreadsheets/d/1pFmnnqexHq16kYLGxr8a794aXnQdyXLm4QmNblk5Fa8/edit?usp=sharing>, colocando o nome dos três componentes do grupo ao lado do nome do conjunto de dados correspondente.

2 As análises

Vamos aplicar um pipeline completo de AM ao conjunto de dados escolhido, utilizando as técnicas vistas em sala de aula. As implementações devem ser feitas em Python em um notebook com anotações, seguindo o roteiro sugerido em: <https://colab.research.google.com/drive/1kUSLOW0ATNBPLTTMbC2U1LGviWYa15rm?usp=sharing>.

ID	Nome
7	audiology
10	lymph
14	mfeat-fourier
22	mfeat-zernike
25	colic
29	credit-approval
31	credit-g
46	splice
51	heart-h
54	vehicle
470	profb
934	socmob
40981	Australian

Tabela 1: Conjuntos de dados que podem ser escolhidos para o projeto.

Apresente os códigos utilizados e discuta os resultados, pois a interpretação deles faz parte do trabalho. As análises compreendem basicamente cinco partes:

1. Descrição básica do conjunto de dados escolhido: pesquise sobre o conjunto de dados escolhido, qual é o seu domínio, sobre o que trata, que problema de predição ele resolve, etc. Apresente algumas características básicas dele, como o número de instâncias, as dimensões, os tipos e as escalas dos atributos, o número de classes, etc.
2. Análise exploratória dos dados: faça uma análise exploratória do conjunto de dados, utilizando estatísticas descritivas e gráficos.
3. Pré-processamentos: discuta quais pré-processamentos são necessários para o conjunto escolhido.
4. Aplicação do *pipeline* de AM: treine modelos de AM nos conjuntos de dados, realizando divisão de dados com validação cruzada e a escolha adequada de hiperparâmetros. Aqui também podem estar incluídos os pré-processamentos de dados indicados anteriormente como necessários. Compare os resultados das técnicas, discuta-os e tire conclusões.
5. Análise dos erros: esta etapa é o diferencial deste trabalho. O conjunto escolhido é reconhecido na literatura como difícil. Então analise possíveis razões que podem ter levado a essa dificuldade. Analise os casos em que os modelos erram mais para verificar se há algum padrão ou *insight*.

A avaliação do projeto será feita com base no notebook entregue e na apresentação do grupo, que deve durar 15 minutos e será agendada para a oitava semana do curso. O notebook e o seu pdf devem ser entregues até 21/09/2026 no Classroom.

3 A análise de erros

Há diversos pacotes para auxiliar na identificação da fonte de dificuldade dos problemas por meio da análise de conjuntos de dados. Seguem alguns que podem ser usados:

- PyHard (Paiva et al., 2021, 2022);
- PyCol (Apóstolo et al., 2025);
- CleanLab (Northcutt et al., 2021);
- H-CAT (Seedat et al., 2024).

Mas vocês também podem tentar usar alternativas de explicabilidade focadas nas instâncias com erros. Por exemplo: LIME (Ribeiro et al., 2016), DICE (Mothilal et al., 2020), etc.

Enfim, nesta etapa do projeto é possível ter criatividade. Não é preciso nem recomendável usar tudo o que foi listado aqui, mas é preciso escolher algo em que focar e fazer uma boa análise e discussão dos resultados alcançados.

Referências

- Apóstolo, D., Santos, M. S., Lorena, A. C., and Henriques Abreu, P. (2025). Pycol: A python package for dataset complexity measures. *Neurocomputing*, 640:130311.
- McElfresh, D., Khandagale, S., Valverde, J., Prasad C, V., Ramakrishnan, G., Goldblum, M., and White, C. (2023). When do neural nets outperform boosted trees on tabular data? *Advances in Neural Information Processing Systems*, 36:76336–76369.
- Mothilal, R. K., Sharma, A., and Tan, C. (2020). Explaining machine learning classifiers through diverse counterfactual explanations. In *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency, FAT* '20*, pages 607–617, New York, NY, USA. Association for Computing Machinery.
- Northcutt, C. G., Jiang, L., and Chuang, I. L. (2021). Confident learning: Estimating uncertainty in dataset labels. *Journal of Artificial Intelligence Research (JAIR)*, 70:1373–1411.
- Paiva, P. Y. A., Moreno, C. C., Smith-Miles, K., de Castro, P. A. L., and Lorena, A. C. (2021). Relating instance hardness to classification performance in a dataset: a visual approach. *Machine Learning, under review*.
- Paiva, P. Y. A., Moreno, C. C., Smith-Miles, K., Valeriano, M. G., and Lorena, A. C. (2022). Relating instance hardness to classification performance in a dataset: a visual approach. *Machine Learning*, 111(8):3085–3123.

- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). "why should i trust you?": Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '16, pages 1135–1144, New York, NY, USA. ACM.
- Seedat, N., Imrie, F., and van der Schaar, M. (2024). Dissecting sample hardness: Fine-grained analysis of hardness characterization methods. In *The Twelfth International Conference on Learning Representations*.